

Εξόρυξη Δεδομένων και Αλγόριθμοι Μάθησης

Στοιχεία μελών:

Διονύσης Παπαδάτος AM: 1100661 e-mail: up1100661@ac.upatras.gr

Σπυρίδων Δριβήλας AM: 1100543 e-mail: up1100543@ac.upatras.gr

Η εκπόνηση της εργασίας έγινε με την έκδοση της python 3.13.13. Συγκεκριμένα για την υλοποίηση των ερωτημάτων χρησιμοποιήθηκαν οι παρακάτω βιβλιοθήκες:

numpy==2.4.4

pandas==3.0.2

matplotlib==3.10.9

seaborn==0.13.2

scipy==1.17.1

scikit-learn==1.8.0

jupyter/notebook==7.5.6

Η παρακάτω αναφορά παρουσιάζει μια συνοπτική περιγραφή των διαδικασιών, προβλημάτων και συγκρίσεων των αποτελεσμάτων των αλγορίθμων. Πιο αναλυτική περιγραφή παρέχεται στα markdown κελιά στο κάθε notebook.

Διαδικασία υλοποίησης του project

Προετοιμασία, Διαχωρισμός και Καθαρισμός Δεδομένων

Η διαδικασία ξεκίνησε με τη φόρτωση του dataset. Στη συνέχεια, αφαιρέθηκαν όλες οι εγγραφές που παρουσίαζαν μηδενικές, ελλιπείς, διπλότυπες ή άπειρες τιμές, εξασφαλίζοντας τη σταθερότητα της ανάλυσης και αποφεύγοντας μελλοντικά προβλήματα στην εκπαίδευση του μοντέλου εκμάνθυσης. Μετά από μία σχολαστική ανάλυση του συνόλου δεδομένων καταλήξαμε ότι την περισσότερη και πιο χρήσιμη πληροφορία την παίρνουμε πρακτικά από 5 βασικές στήλες. Αυτό μετά οπτικοποιήθηκε και επιβεβαιώθηκε.

Έπειτα, ακολούθησε εύρεση και αφαίρεση των χαρακτηριστικών που παρουσίαζαν μεταξύ τους είτε πολύ μεγάλη συσχέτιση είτε πολύ χαμηλή διακύμανση καθώς με αυτόν τον τρόπο μειώσαμε τον θόρυβο στο dataset και το υπολογιστικό κόστος. Σε αυτό το σημείο έγινε και η αφαίρεση της στήλης «Label» καθώς δεν θα χρησιμοποιηθεί για την εκπαίδευση του μοντέλου εκμάνθυσης. Τελευταία βήματα στην προετοιμασία των δεδομένων ήταν η κωδικοποίηση της στήλης «Label» σε αριθμούς για την ομαλή χρήση από τους αλγορίθμους και ο διαχωρισμός των δεδομένων. Ο διαχωρισμός έγινε σε δύο σενάρια. Σενάριο A τα δεδομένα μοιράστηκαν σε Train / Validation / Test Split με ποσοστά αντίστοιχα 60% / 20% / 20% και σενάριο B (Cross-Validation) train / test split με με ποσοστά αντίστοιχα 80% / 20%. Τέλος, εφαρμόστηκε standard scaler φίλτρο αποκλειστικά στα δεδομένα που ανήκουν στο train κομμάτι.

Έρευνα ιδανικών υπερπαραμέτρων των δοθέντων αλγορίθμων, Εκπόνηση των δύο σεναρίων

Η διαδικασία συνεχίστηκε ακολουθώντας την δομή: επιλογή σεναρίου→επιλογή αλγορίθμου ταξινόμησης→έρευνα βέλτιστων υπερπαραμέτρων→εμφάνιση αποτελεσμάτων αλγορίθμου και ανάλυση.

Συγκεκριμένα η αρχή έγινε με το σενάριο A. Για κάθε έναν από τους τρεις αλγορίθμους διεξήχθη έρευνα βέλτιστων υπερπαραμέτρων με μετρική σύγκρισης την F1-score καθώς αποτελεί την πιο αντικειμενική από τις υπόλοιπες λόγω του μεγάλου προβλήματος του class imbalance που υπάρχει. Αξίζει να σημειωθεί ότι παρά την θέλησή μας για εύρεση της πιο ιδανικής υπερπαραμέτρου με όσο μεγαλύτερο F1-score, χρειάστηκε να γίνουν κάποιοι συμβιβασμοί λόγω του τεράστιου όγκου δεδομένων του dataset. Για αποφυγή ατελειών των ωρών εκτέλεσης αλγορίθμων και επιβάρυνση της μνήμης RAM του kernel χρησιμοποιήθηκε η μεταβλητή max_iter=150 για τον περιορισμό των επαναλήψεων και συντομότερη εκτέλεση των αλγορίθμων. Στην συνέχεια υλοποιήθηκε κάθε ένας από τους ζητούμενους αλγορίθμους με τις ιδανικές υπερπαραμέτρους που βρήκαμε και εμφανίστηκαν οι αναλυτικοί πίνακες αποτελεσμάτων και confusion matrix.

Η ίδια διαδικασία επαναλήφθηκε και στο σενάριο B. Ωστόσο, λόγω πάλι των προαναφερθέντων προβλημάτων χρόνου και μνήμης χρησιμοποιήθηκαν 3 folds στον cross-validation, ενώ ένας αριθμός όπως 5 ή 6 θα πετύχαινε καλύτερα σκορ απόδοσης.

Προετοιμασία Δεδομένων για Clustering, εκτέλεση αλγορίθμων

Για την καλύτερη εκπόνηση αυτού του ερωτήματος δημιουργήθηκε νέο notebook, στο οποίο κρατήθηκαν τα κελιά που επεξεργάζονταν τα δεδομένα ώστε να καταλήξουμε στον τελικό πίνακα με τα τελικά χαρακτηριστικά. Μετά, εφαρμόστηκε στα δεδομένα φίλτρο Standard Scaler σε όλο το σύνολο των δεδομένων, καθώς κρίθηκε ως η καλύτερη επιλογή ώστε να μπορέσει να γίνει μια αντικειμενική σύγκριση ανάμεσα στους τρεις αλγορίθμους. Στη συνέχεια, εφαρμόστηκε δειγματοληψία στις 10.000 εγγραφές, διότι οι αλγόριθμοι DBSCAN και Hierarchical Clustering θα παρουσίαζαν πλήρη αδυναμία διαχείρισης τόσο μεγάλου όγκου δεδομένων. Τέλος, πραγματοποιήθηκε ανάλυση PCA διατηρώντας το 95% της διακύμανσης των δεδομένων, με σκοπό την καλύτερη οπτικοποίηση των αποτελεσμάτων των αλγορίθμων.

Η διαδικασία συνεχίστηκε με την αναζήτηση των ιδανικών υπερπαραμέτρων για κάθε έναν από τους τρεις αλγορίθμους ομαδοποίησης, με σκοπό τη μεγιστοποίηση της διαχωριστικής τους ικανότητας. Για τον αλγόριθμο K-Means, η εύρεση του βέλτιστου αριθμού ομάδων πραγματοποιήθηκε μέσω της γεωμετρικής μεθόδου του «αγκώνα», η οποία υπέδειξε ως

καταλληλότερη την επιλογή των 5 clusters. Στην περίπτωση του πυκνομετρικού αλγορίθμου DBSCAN, εξετάστηκαν διαφορετικοί συνδυασμοί για την ακτίνα γειτονιάς και τον ελάχιστο αριθμό δειγμάτων, επιτρέποντας στο μοντέλο να εντοπίζει αυτόματα τις περιοχές υψηλής πυκνότητας και να απομονώσει τα ακραία στοιχεία ως θόρυβο. Για τον Hierarchical Clustering, αναλύθηκε η δομή του παραγόμενου δενδρογράμματος με βάση τη μέθοδο ελάχιστης διακύμανσης, επιλέγοντας το τελικό «κόψιμο» του δέντρου σε 4 διακριτές ομάδες.

Σύγκριση Αποτελεσμάτων Αλγορίθμων Ταξινόμησης

Ο παρακάτω πίνακας παρουσιάζει τις βέλτιστες υπερπαραμέτρους που επιλέχθηκαν και το τελικό Macro F1-Score για κάθε μοντέλο και στα δύο Σενάρια Αξιολόγησης.

Logistic Regression

Σενάριο A: C = 10.0 | Σκορ F1: 0.57

Σενάριο B: C = 10.0 | Σκορ F1: 0.57

Decision Tree

Σενάριο A: Max_Depth = 20 | Σκορ F1: 0.87

Σενάριο B: Max_Depth = 25 | Σκορ F1: 0.86

Random Forest

Σενάριο A: N = 50, Max_Depth = None | Σκορ F1: 0.85

Σενάριο B: N = 50, Max_Depth = None | Σκορ F1: 0.86

Κοινό Test Set (20%): Και στα δύο σενάρια, η τελική βαθμολόγηση έγινε στο ίδιο, απολύτως απομονωμένο και κρυφό Test Set για να διασφαλιστεί η αντικειμενικότητα της σύγκρισης.

Σταθερότητα μεταξύ Σεναρίου A και Σεναρίου B

Η επίδοση των μοντέλων παρέμεινε ουσιαστικά σταθερή και στα δύο σενάρια (μικρές διακυμάνσεις της τάξης του 0.01). Αυτή η συμπεριφορά οδηγεί σε δύο σημαντικά συμπεράσματα:

1. Το αρχικό τυχαίο split (60/20/20) στο Σενάριο A ήταν ήδη πολύ αντιπροσωπευτικό και δεν περιείχε στατιστική μεροληψία (bias).
2. Το Cross-Validation στο Σενάριο B επιβεβαίωσε επιστημονικά ότι οι βέλτιστες παράμετροι και οι ικανότητες των μοντέλων είναι πραγματικές και σταθερές, αποκλείοντας τον παράγοντα της τυχαιότητας.

Διαχείριση Ανισορροπίας Κλάσεων (Class Imbalance)

Παρά το γεγονός ότι η γενική ακρίβεια (Accuracy) όλων των μοντέλων αγγίζει το υποδειγματικό 97% - 100% (λόγω της κυριαρχίας των 'BENIGN' δειγμάτων), το Macro F1-Score αποτελεί τη μοναδική αξιόπιστη μετρική για την κυβερνοασφάλεια. Το Random Forest και το Decision Tree αναδεικνύονται ως οι μοναδικοί ασφαλείς ταξινομητές, καθώς προστατεύουν το δίκτυο από Ψευδώς Αρνητικά (False Negatives) αποτελέσματα στις σπάνιες αλλά κρίσιμες επιθέσεις.

Σύγκριση αλγορίθμων

Καλύτερος αλγόριθμος με μικρή διαφορά αναδείχθηκε ο Decision Tree και αμέσως μετά ο Random Forest. Παρότι ο Decision Tree είχε το υψηλότερο F1-score ο Random Forest εμφάνισε καλύτερη επίδοση σε κλάσεις με ελάχιστο αριθμό εγγραφών.

Σύγκριση Αποτελεσμάτων Αλγορίθμων Ομαδοποίησης

Ο παρακάτω πίνακας παρουσιάζει τις βέλτιστες υπερπαραμέτρους που επιλέχθηκαν και τις τελικές εσωτερικές μετρικές αξιολόγησης για κάθε μοντέλο ομαδοποίησης.

K-Means

Βέλτιστο k: 5 Clusters

Δείκτης Silhouette: 0.3194

Δείκτης Davies-Bouldin: 1.1918

DBSCAN

Παράμετροι: eps = 0.5, min_samples = 10

Δείκτης Silhouette: 0.2666
Δείκτης Davies-Bouldin: 1.5047

Hierarchical Clustering

Βέλτιστο k: 4 Clusters

Δείκτης Silhouette: 0.5236

Δείκτης Davies-Bouldin: 0.9895

Κοινό PCA dataset: Και στους τρεις αλγορίθμους, η τελική εκπαίδευση και βαθμολόγηση έγινε πάνω στο ίδιο, στρατοποιημένο δείγμα των 10.000 εγγραφών με διατήρηση του 95% της διακύμανσης, ώστε να διασφαλιστεί η αντικειμενικότητα και η υπολογιστική σταθερότητα της σύγκρισης.

Σταθερότητα μεταξύ Γεωμετρικών Δεικτών και Πρακτικής Εφαρμογής

Η επίδοση των μοντέλων παρουσίασε μια έντονη αντίθεση ανάμεσα στους μαθηματικούς δείκτες και την επιχειρησιακή τους χρησιμότητα. Αυτή η συμπεριφορά οδηγεί σε δύο σημαντικά συμπεράσματα:

1. Η Hierarchical Clustering πέτυχε το υψηλότερο Silhouette Score (0.5236), επιβεβαιώνοντας μαθηματικά ότι κατασκευάζει εξαιρετικά συμπαγείς και καλά διαχωρισμένες σφαιρικές ομάδες.
2. Η διασταύρωση με τα πραγματικά Labels έδειξε ότι, παρά το χαμηλότερο Silhouette, ο K-Means προσέφερε πιο ουσιαστική και σταθερή πληροφορία στην πράξη, καθώς απέφυγε τη δημιουργία μιας ενιαίας «υπερ-ομάδας» που θα ισοπέδωνε τις διαφορές των δεδομένων.

Διαχείριση Ανισορροπίας Κλάσεων (Class Imbalance) & Διασπορά του BENIGN

Παρά το γεγονός ότι οι γεωμετρικοί δείκτες βαθμολογούν θετικά τα μοντέλα, η κυριαρχία των BENIGN δειγμάτων αναγκάζει τους Unsupervised αλγορίθμους να «σπάσουν» την κανονική κίνηση σε πολλαπλά clusters λόγω της εσωτερικής της ποικιλομορφίας. Αυτά τα μεγάλα clusters λειτουργούν ως «μαγνήτες» λόγω του όγκου τους, με αποτέλεσμα οι πιο εξελιγμένες επιθέσεις επιπέδου εφαρμογής (όπως οι Web Attacks και το Brute Force) να απορροφηθούν ολοκληρωτικά μέσα τους, καθώς μιμούνται τη συμπεριφορά των νόμιμων χρηστών και παρουσιάζουν γεωμετρική επικάλυψη (overlapping).

Σύγκριση αλγορίθμων

Ο αλγόριθμος με τις καλύτερες μετρικές αναδείχθηκε ο Hierarchical Clustering, ενώ ο K-Means εμφάνισε καλύτερη συμπεριφορά καθώς απέφυγε να «καταπιεί» όλες τις απειλές σε ένα cluster, καταφέροντας να απομονώσει με μεγάλη ακρίβεια τις επιθέσεις μεγάλου όγκου). Τέλος, ο DBSCAN λειτούργησε αποτελεσματικά αποκλειστικά ως φίλτρο εντοπισμού ακραίων τιμών (outliers).